

데이터와 서비스가 동작하는 과정

네 프로젝트의 문제 · 처리 흐름 · 운영 관점

최현규

데이터 엔지니어링 · MLOps

이전에는 이커머스 플랫폼을 1인 개발·운영했으며,
현재는 데이터 엔지니어링과 MLOps를 중심으로 역량을 확장하고 있습니다.

01

Auto Research

02

서울 기상 알림

03

Ecommerce ETL

04

Construction Risk Agent

기존 발표자료·대시보드 통합 검토본 · 2026.09.15

네 프로젝트를 읽는 공통 기준

각 프로젝트는 소개 → 처리 흐름 → 대시보드 순서로 구성했습니다.

01 Auto Research

ML 실험 자동화

담당: 클라우드 인프라 · 배포 · 관측

2026.06-08 · 5인 팀

02 서울 기상 알림

Air Quality Project

담당: 수집 · 이벤트 처리 · 저장 · 알림 · 운영 개선

2026.04-09 · 개인 프로젝트

03 Ecommerce ETL

이종 주문 데이터 통합

담당: 원천별 수집 · 스키마 매핑 · 품질 검사 · 로컬 적재

2026.09 · 개인 프로젝트

04 Construction Risk Agent

건설 리스크·추가비용 산정

담당: 라우터 · 결과 합성 · 장비비 에이전트

2026.06 · 5인 팀

대시보드는 발표용 통합 화면입니다. 예시 값·과거 검증 기록·현재 구현 범위를 구분합니다.

Auto Research

2026.06-08 · 5인 팀 | 담당: 클라우드 인프라 · 배포 · 관측

가설 한 줄에서, 검토 가능한 실험 결과까지

코드 수정·학습 실행·결과 해석 사이의 수작업을 줄이고, 연구자가 가설과 최종 판단에 집중할 수 있는 실험 환경을 구성했습니다.

반복 가능한 실험

가상 사용자 반응과 CTR 학습·추천을 연결합니다.

검토 가능한 근거

동일 조건의 기준·후보 모델 비교, 코드·지표·리포트를 남깁니다.

격리된 실행 환경

GKE Job으로 실험을 분리하고 실행 자원을 관리합니다.

기술 구성

Terraform · GKE · GitHub Actions · ArgoCD · Airflow · Feast · MLflow

데이터 순환과 가설 검증, 두 개의 루프

Auto Research | 구조와 설계 판단

데이터 피드백 루프



추천 노출에 대한 반응을 다시 수집해 다음 학습에 활용합니다.

가설 기반 실험 루프



모델의 지표 기반 자동 승격과 가설 실험의 사람 최종 판단은 별도 절차입니다.

구축

초기 Terraform 리소스 25개 · 1주일 내 개발 기반 구성

관측

8개 이슈로 분해 · 1.5일 내 관측 환경 배포·검증

복구

tfvars·NetworkPolicy 불일치 진단 · 누락 KSA를 IaC 편입

실행 상태와 실험 근거를 함께 확인

Auto Research | 발표용 운영 화면 · 실시간 연동 없음

약 7,000명

가상 사용자 · 발표 기준

일 200편

영상 후보 · 발표 기준

약 140만

사용자×영상 조합/일

2개 역할

실행 Agent · 독립 리뷰

처리 상태를 읽는 기준

등록·실행

CREATED → RUNNING

평가·통과

EVALUATING → PASSED

분기·판단

FAILED / ERROR · 사람의 승격

결과 · 근거 · 운영 기록

· 비교 지표: ROC-AUC · LogLoss · Brier

· 근거: 데이터 이력 · 코드 변경 · 실행 로그

· 산출물: metrics · report · dev PR

· 연구자 판단: 반영 · 폐기 · 다음 가설

구조 설명용입니다. 수치는 최종 발표 기준이며 현재 실측 처리량이 아닙니다. 컨테이너 개수는 자료별 차이가 있어 일반화하지 않았습니다.

서울 기상 알림

2026.04-09 · 개인 프로젝트 | 담당: 수집 · 이벤트 처리 · 저장 · 알림 · 운영 개선

공공 데이터를 상태 판정과 행동 권고로

기상청·에어코리아 지수 9종을 하루 4회 수집합니다. 결측과 실패를 구분하면서 Kafka를 거쳐 판정 이력을 저장하고 카카오톡·이메일·Slack으로 알림을 보냅니다.

결측은 정보없음

누락된 값을 0이나 좋은 상태로 바꾸지 않습니다.

재처리 가능한 이벤트

event ID upsert·수동 커밋·DLQ로 재처리 경로를 둡니다.

전송 결과에 따른 상태

전송 성공 시 중복 억제 상태를 기록하고 실패를 추적합니다.

기술 구성

Python · Airflow · Kafka · OpenSearch · Docker Compose · 카카오톡 / 이메일 / Slack

수집·판정·저장·알림의 실패 경계를 분리


서울 기상 알림 | 구조와 설계 판단

수집과 이벤트 처리




발표 시각·수집 시각·예정 실행 슬롯을 구분해 재시도의 이벤트를 의미합니다.

저장과 전달



하단은 처리 결과별 분기입니다. 수동 커밋은 at-least-once이며 알림 중복 가능성을 완전히 없애지는 않습니다.



결측·전송 결과·운영 개선을 한 화면에

서울 기상 알림 | 발표용 운영 화면 · 실시간 연동 없음

4회/일

정기 수집 · KST 기준

4.4–16초

E2E · 기존 로컬 측정

100–300ms

메시지 처리 · 기존 측정

248개

09.15 pytest 통과

처리 상태를 읽는 기준

데이터 계약

정보없음 구분 · event_id · DLQ

전달·관측

처리 메트릭 · 구조화 로그 · 쿨다운

운영 경계

로컬 검증 · 대규모 처리량 주장 없음

결과 · 근거 · 운영 기록

- 파일 기반 시크릿 주입 · 최소 권한·TLS 구성
- Airflow PostgreSQL·병렬 실행 · 고정 이미지 빌드
- watcher·성능 측정 구현 · 외부 전송은 이번 미검증
- 운영 한계: watcher는 발송 실패에도 쿨다운 기록

09.15 pytest 248개·커버리지 56.75% 확인. 지연은 기존 로컬 측정입니다. 별도 watcher의 발송 실패 후 재알림 억제 문제는 남아 있습니다.

Ecommerce ETL

2026.09 · 개인 프로젝트 | 담당: 원천별 수집 · 스키마 매핑 · 품질 검사 · 로컬 적재

서로 다른 주문 데이터를 같은 계약으로

PG CSV·오픈마켓 HTTP API·GA4 보고서의 다른 구조를 주문 라인 단위로 통합합니다. 합성 데이터와 목업을 사용해 수집부터 DuckDB 적재까지 재현합니다.

원천별 수집 분리

Airflow DAG 3개로 각 원천의 입력과 실패 지점을 나눕니다.

18컬럼 통합 계약

source 포함 키 · UTC 시각 · KST 기준일 · 정수 KRW를 사용합니다.

날짜별 재적재

품질 검사 후 트랜잭션으로 대상 날짜를 교체합니다.


기술 구성

Python · Airflow · pandas · PyArrow / Parquet · DuckDB · Docker Compose

세 원천의 staging을 모아 날짜 단위로 적재

Ecommerce ETL | 구조와 설계 판단

원천별 수집



앞의 세 원천은 병렬 입력입니다. 실제 GA4 API 연결과 실제 거래 간 중복 제거는 별도 범위입니다.

수동 통합 적재



warehouse_orders_load는 별도 수동 실행 DAG입니다. BigQuery는 설계 목표로 남겨두었습니다.

Q1-Q3

필수값 · 라인 키 중복 · 수량·금액 범위

Q4-Q7

금액 산식 · KST 날짜 · source · 미래 시각

리뷰·재현

이슈·계획·Draft PR·리뷰·머지 / venv·Docker

수집·품질·적재의 검증 범위를 확인

Ecommerce ETL | 발표용 운영 화면 · 실시간 연동 없음

3개

원천별 수집 DAG

18개

통합 주문 컬럼

152행

기존 E2E 기록

0건

기존 재실행 중복 기록

처리 상태를 읽는 기준

수집 DAG 3개

PG 46행 · 오픈마켓 45행 · GA4 61행

통합 DAG 1개

152행 · 2회 실행 · 다른 날짜 1개 보존

Q1-Q7 검사

위반률 0.00% / 임계 1% · 원본 기록

결과 · 근거 · 운영 기록

- 기존 Docker E2E 대상일: 2026-09-01 · 실시간 아님
- 09.15 pytest: 91 통과·1 스킵 (Airflow 미설치)
- 재실행 검증은 정상 입력 기준 · 날짜 교체 경계 존재
- BigQuery·GA4 실연결·서비스 분석 화면은 후속

합성·목업 데이터의 기존 E2E 결과입니다. 적재 함수 직접 호출의 대상일 혼입·부분 입력·동시 실행은 추가 검증이 필요하며 합산 금액은 총매출이 아닙니다.

Construction Risk Agent

2026.06 · 5인 팀 | 담당: 라우터 · 결과 합성 · 장비비 에이전트

질문을 계산 근거가 있는 비용 리포트로

공사 조건·기간·공종을 담은 질문에서 필요한 도메인을 선택합니다. 기상·장비·자재·노무비 결과와 문서 근거를 모아 공무 담당자용 리포트로 합성합니다.

질문별 실행 범위

CHAT·RAG_QA·COST_REPORT·RISK_REF
구분합니다.

필요한 계산 선택

비용·리스크 리포트에서 필요한
날씨·비용 노드를 선택합니다.

결과와 근거 합성

비용·지연·문서 근거와 확인 항목을 함께
제시합니다.

기술 구성

Python · LangGraph · AWS Bedrock · PostgreSQL / pgvector · FastAPI · RAG

분류 → 필요한 에이전트 → 결과 합성

Construction Risk Agent | 구조와 설계 판단

팀 서비스 실행 흐름



모든 질문에 모든 도구를 실행하지 않습니다. 불필요한 호출과 근거 혼입을 줄이는 구조입니다.

본인 담당: 장비 대기비



라우터·synthesize와 장비비 로직, 관련 DB 스키마·초기 데이터·테스트를 담당했습니다.

실행 기반

LangGraph · FastAPI · AWS Bedrock

데이터·근거

PostgreSQL·pgvector · RAG · 기상청 API

담당 경계

백엔드 인증·프론트엔드·다른 비용 노드는 팀원 담당

질문 하나가 리포트가 되기까지

Construction Risk Agent | 발표용 운영 화면 · 실시간 연동 없음

~~₩~~4.82M

예상 추가비용 · 예시

3.0일

예상 지연 · 예시

12건

근거 문서 · 예시

높음

신뢰도 표시 · 예시

처리 상태를 읽는 기준

질문·분류

공사 조건 입력 → Router

도메인 실행

Weather · 선택된 Cost 노드

리포트 생성

Synthesize · 근거 문서 연결

결과 · 근거 · 운영 기록

· 예시: 강수로 작업 가능일이 3일 감소할 가능성

· 예상 추가비용 약 ~~₩~~4.82M · 근거 문서 12건

· 장비 대기비를 포함한 결과와 확인 항목 제공

· 실제 비용·지연은 입력값·외부 API 응답에 따라 달라짐

금액·일수·문서 수·신뢰도는 기존 PPT의 예시를 보존한 값입니다. 실제 현장 비용이나 측정된 정확도를 의미하지 않습니다.